

Lyndon 数组, Lyndon 树, 一个简介

EtaoinWu¹

说明: 这篇基本是^[1]的翻译。

1 基本定义

给定一个有限集 Σ , 称作**字符集**。称 Σ^* (Σ 的任意长序列的集合, 又称为“ Σ 上的自由幺半群”) 的一个元素为一个**字符串**。借用自由幺半群的记法, 用乘法 (或者中间什么都不写) 来表示字符串和 / 或字符的拼接。使用 $|s|$ 表示字符串 s 的**长度**。使用 $s[i]$ 表示 s 中第 i 号位置的元素, $1 \leq i \leq |s|$ 。称 $s[l..r] = s[l]s[l+1]\dots s[r]$ 为 s 的**子串**。
 $s[1..k], s[k..|s|]$ 分别称作 s 的**前缀**、**后缀**。 $\text{pre}(s, k) := s[1..k]$, $\text{suf}(s, k) := s[|s| - k + 1, |s|]$ 。

对于一棵二叉树, 我们定义一个**左结点**是根或其父亲的左孩子, **右结点**同理。

2 字符串的等价与自等价

若 $\forall 1 \leq x < |s| - p, s[x] = s[x + p]$, 就称数字 p 是 s 的一个**周期**。若字符串 t 既是 s 的一个前缀, 又是 s 的一个后缀, 称 t 是 s 的一个**border**。

p 是 s 的一个周期当且仅当 $\text{pre}(s, |s| - p)$ 是 s 的一个 border。

¹ 北京大学, 信息管理系, wu.y@pku.edu.cn。

引理 甲：如果 p, q 都是字符串 s 的周期， $p + q \leq |s|$ ，则 $\gcd(p, q)$ 也是 s 的周期。

证明可以考虑设 $p > q$, $s[i] = s[i + p - q] = s[i - q + p]$, 从略。

推论：一个字符串 s 的所有 $\leq \frac{|s|}{2}$ 的周期都是最小周期的整数倍。

推论：一个字符串的所有长度过半的 border 构成一个等差数列。

Border 的结构：考虑一个字符串的长度在 $2^{-k}|s|$ 到 $2^{1-k}|s|$ 之间的 border，所有这样的 border 都是其中最长者的“过半 border”。因此，一个字符串的所有 border 构成至多 $\log_2 n$ 段等差数列。

若两个字符串 s, t 满足存在字符串 v, w 使得 $s = vw, t = wv$ ，那么我们称它们 **循环同构**（有的文献上称作**共轭**）。一个充要条件是 s 是 t 的子串。

2.1 Runs

定义一个字符串 w 里的一个 **run**，指其内部一段两侧都不能扩展的周期子串，且周期至少完整出现两次。严格地说，一个 run 是一个三元组 (i, j, p) ，满足 p 是 $w[i..j]$ 的最小周期， $j - i + 1 \geq 2p$ ，且满足如下两个条件：要么 $i = 1$ ，要么 $w[i - 1] \neq w[i - 1 + p]$ ；要么 $j = n$ ，要么 $w[j + 1] \neq w[j + 1 - p]$ 。

对于一个 run，其任一长度为 p 的子串称作其一个 root。

我们用 $\text{Runs}(w)$ 表示 w 的所有 run 的集合。本文的主要结果是如下定理。

定理 甲，Runs Theorem: $|\text{Runs}(w)| < |w|$ 。

为了证明这一定理，我们需要一些别的东西。

3 字符串的序

方便起见，我们设 \prec_0 代表 Σ 上的小于， \prec_1 代表 Σ 上的大于。每种字符序都可以诱导一个字典序（逐一比较；一个串的前缀小于其自身），滥用符号也记为 $\prec_\ell, \ell \in \{0,1\}$ 。举例来说，如果 $a \prec_0 b$ ，那么 $b \prec_1 a$ ，并且 $a \prec_0 ab, a \prec_1 ab$ 。

3.1 后缀数组

对于一个字典序 \prec ，我们可以对一个字符串 w 的所有后缀排序。把这些排序好的后缀的左端点的下标放到一个数组中，称作 **后缀数组** $SA(w)$ 。很明显这是一个排列；其逆排列记作 **排名数组** $ISA(w)$ ，OI 中常见称作 $rank$ 。对 SA 上相邻两个位置对应的后缀求最长公共前缀 (LCP)，得到 LCP 数组 $height(w)$ 。

对 $height_n$ 做区间最值查询 (RMQ)，可以求字符串任意两个子串的最长公共前缀，这是熟知的。

一个应用是，给定 i, p ，查询从 i 开始、周期为 p 的最长子串。很明显， $lcp(w[i..], w[i + p..]) + p$ 就是答案。

3.2 Lyndon 串

给定一个 \prec 。如果一个字符串 s 小于其所有后缀，那么称它是一个 **Lyndon 串 (Lyndon word)**。其充要条件是， s 小于其所有循环移位。其充要条件是，对于所有拆分 $s = vw$ ，都有 $v \prec w$ 。

引理 乙：如果 v, w 是两个 Lyndon 串， $v \prec w$ ，那么 vw 是一个 Lyndon 串。

证明： $v \prec w$ 的两种情况是 $v \in \text{pre}(w)$ 或 $\exists i, v[i] \prec w[i]$ 。这两种情况下都有 $vw \prec w$ 。 vw 的后缀要么是 $\text{suf}(v)w$ ，要么是 $\text{suf}(w)$ ，这二者都能证明 $\prec vw$ 。

3.3 Lyndon 分解

定理二，Chen-Fox-Lyndon Theorem：任何字符串可以唯一分解成若干个单调不上升的 Lyndon 串的续接。即对于任意字符串 s ，有唯一的 $s = s_1 s_2 \cdots s_k$ ，其中 $s_1 \succcurlyeq s_2 \succcurlyeq \cdots \succcurlyeq s_k$ ，且 s_i 都是 Lyndon 串。

这样的分解被称为 **Lyndon 分解**。

证明：先证存在性。最初 $s = s[1]s[2]\cdots s[n]$ （单字符都是 Lyndon 串），然后只要存在相邻两段满足前面 \prec 后面，就把它们合并起来（引理乙）。唯一性的证明由下面的引理丙自然可知。

引理丙：一个串的 Lyndon 分解的第一个串一定是其最长 Lyndon 前缀。

应用反证法，设 \tilde{s} 是 s 的最长 Lyndon 前缀，则有 $\tilde{s} = s_1 s_2 \cdots s_k \text{pre}(s_{k+1}, l)$ ，则 $\tilde{s} \prec \text{pre}(s_{k+1}, l) \preccurlyeq s_{k+1} \preccurlyeq s_1 \prec \tilde{s}$ 。

引理丁：一个串的 Lyndon 分解的最后一个串一定是其最小后缀。
证明从略。

3.3.1 Duval 算法

不断求一个串的最长 Lyndon 前缀，以计算其 Lyndon 分解。

引理戊：设 $w = u^k u' a$ ，其中 u 是一个 Lyndon 串， u^k 表示 u 重复 k 次， u' 是 u 的一个可能空的前缀，字符 $a \neq u[|u'| + 1]$ 。若 $a \succ u[|u'| + 1]$ ，那么 w 是一个 Lyndon 串。若 $a \prec u[|u'| + 1]$ ，那么所有 w 开头的字符串的最长 Lyndon 前缀是 u 。

证明是十分简单的。

Duval 算法的主要过程是，在字符串中不断迭代，并不断保持引理戊的条件。最初 $w = u = \varepsilon$ 。不断向 w 的最后添加字符，设向 $w = u^k u'$ 中加入字符 a 。(1)如果 $a = u[|u'| + 1]$ 则继续。(2)如果 $a \succ$

$u[|u'| + 1]$, 我们令 $u \leftarrow u^k u' a$ 。 (3)如果 $a \prec u[|u'| + 1]$, 输出 k 个 u , 然后从 u' 的开头处重新开始主算法。

具体算法代码可以看 LibreOJ #129。

这一算法的时间复杂度是线性的, 额外空间是常数的。时间线性可以如下证明: (3)的总输出量是 n , 并且每次向左重新开始的跳跃距离 $|u'| < |u| < k|u|$ 即这一次的输出量, 因此总的回跳量是 $< n$ 的; 因此添加字符的总次数 $< 2n$ 。

3.4 Lyndon 数组

对于一个字符串 s , 我们定义 $\text{LA}(w)$ 是这样一个数组, 这一数组的下标为 k 的位置为 $w[k]$ 开头的最长 Lyndon 子串的长度。这称作 **Lyndon 数组 (Lyndon array)**。注意, 此节往后, 我们讨论的字符串都加入了一个 \prec_0 意义下的无穷小字符\$。在 \prec_1 意义下, 它便是无穷大。

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
T =	b	a	n	a	a	n	a	n	a	a	n	a	n	a	\$
SA =	15	14	9	4	12	7	2	10	5	1	13	8	3	11	6
ISA =	10	7	13	4	9	15	6	12	3	8	14	5	11	2	1
NSV _{ISA} =	2	4	4	9	7	7	9	9	14	12	12	14	14	15	16
LA =	1	2	1	5	2	1	2	1	5	2	1	2	1	1	1
Lyndon factors	\underline{b}	\underline{a}	\underline{n}	\underline{a}	\underline{a}	\underline{n}	\underline{a}	\underline{n}	\underline{a}	\underline{a}	\underline{n}	\underline{a}	\underline{n}	\underline{a}	$\underline{\$}$
			\underline{n}		\underline{a}	\underline{n}	\underline{a}	\underline{n}		\underline{a}	\underline{n}	\underline{a}	\underline{n}		
					\underline{n}	\underline{n}				\underline{n}	\underline{n}			\underline{n}	

图表 3-1 Lyndon 数组的展示^[2]

引理 己, $\text{SA} \Rightarrow \text{LA}$: 如果 $\text{LA}(i) = j - i + 1$, 那么 $\text{ISA}_{j+1} < \text{ISA}_i$, 且 j 是最小的满足这一性质的数。

请自行验证。这说明了 Lyndon 数组可以在线性时间内构造。对于两个序 \prec_0, \prec_1 , 我们可以定义 LA_0 和 LA_1 两个数组。

引理 庚: 对于两个序 \prec_0, \prec_1 , $\text{LA}_0(i)$ 和 $\text{LA}_1(i)$ 恰好有一个是 1。

证明: 设 $w[i]$ 右边第一个不同于 $w[i]$ 的字符是 $w[j]$, 且 $w[j] \prec_\ell w[i]$ 。那么由引理 戊, $w[i..j]$ 是一个 \prec_ℓ Lyndon 串, 且 $w[i]$ 是其开头最长的 $\prec_{1-\ell}$ Lyndon 串。

3.5 Lyndon-ness 与 run

对于一个 run $r = (i, j, p)$, 我们设 $\ell_r \in \{0, 1\}$ 满足 $w[j+1] \prec_{\ell_r} w[j+1-p]$ 。如果其一个子串既是它的根 (长度为 p) 又是 Lyndon word, 那么称这个子串是它的一个 **L-root**。

引理 辛: 一个 run 的任一 L-root 一定恰好是这个根的左端点的 LA_{ℓ_r} 。

证明和引理 庚几乎完全相同。由这一引理立即可以得出, $|\text{Runs}(w)| \leq 2|w|$ 。因此我们转而分析一个 run 的所有 L-root 的左端点。设 \overline{B}_r 表示一个 run 的所有 L-root 的左端点集合, $B_r = \overline{B}_r \setminus \{i\}$ 。显然 B_r 非空。

我们可以发现如下的引理:

引理 壬: 不同的 run 有不相交的 B_r 。

采用反证法, 假设 $i \in B_r \cap B_{r'}$ 。设 $[i..j]$ 和 $[i..j']$ 分别是 r, r' 的 L-root, 由引理 辛可知, j 和 j' 中恰有一个 $= i$ 。不妨设 $i = j' < j$ 。由 B 的定义去掉了 run 的左端点, 知 $i-1$ 也包含于两个 run 中。由 r' 的周期为 1, 知 $w[i-1] = w[i]$; 由 r , 知 $w[i-1] = w[j]$ 。那么 $w[i] = w[j]$, 因此 $w[i..j]$ 不是 Lyndon 串, 矛盾。

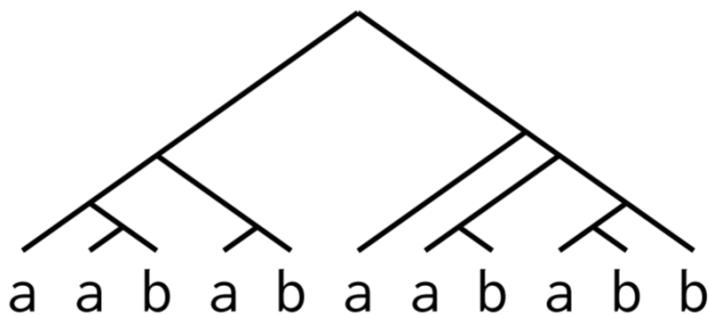
定理 甲, Runs Theorem: $|\text{Runs}(w)| < |w|$ 。

证明： $|Runs(w)| = \sum_{r \in Runs(w)} 1 \leq \sum_{r \in Runs(w)} |B_r| = |\bigcup_r B_r| \leq |\{2, \dots, |w|\}| = n - 1 < n$ 。

利用以上结论，我们可以求所有 run 的位置：在两个LA数组中枚举位置，得到一个可能的 L-root，向两侧扩展，判断是否合法，然后去重即可。

4 Lyndon 树

对于一个长度大于一的 Lyndon 串 w ，设 $w = uv$ ，其中 v 是其所有真后缀中字典序最小的，可以证明 u, v 都是 Lyndon 串。我们称这样的分解方式为 **标准分解**。递归进行这样的分解，可以得到一个树结构，称作 **Lyndon 树**（Lyndon tree）。



图表 4-1 aababaababb 的 Lyndon 树结构

对于 Lyndon 树的结构和 Lyndon 子串的关系，我们有如下引理：

引理 壴：设 $w[l..r]$ 是一个 Lyndon 子串。对所有 $[l..r]$ 范围内的叶子求 LCA，得到的节点对应的区间设为 $[i..j]$ 。则 $l = i$ 。

证明：设 $[i..j]$ 这个结点的左右儿子分别是 $[i..k], [k+1..j]$ 。注意到 $i \leq l \leq k < k+1 \leq r \leq j$ 。设 $u = w[i..l-1], s = w[l..k], t = w[k+1..r], v = w[r+1..j]$ 。则 $w[l..r] = st$ 是 Lyndon 串，那么 $st \prec t$ ，则 $stv \prec tv$ ，但 tv 是 $w[i..j] = ustv$ 的最小真后缀，那么只能 $u = \epsilon$ 。

这是说，一个非叶右结点的左端点开头的 Lyndon 串都在这个非叶结点内部。因此，这个端点开头的最长 Lyndon 串就是这个非叶右结点本身。这告诉我们，已知 $\text{LA}(s)$ ，用一个单调栈就可以求算其 Lyndon 树。

对于非 Lyndon 的串，我们可以在前面加一个（比最后那个更小的）无穷小字符，然后求 Lyndon 树。注意，为了保证 Lyndon 性，在有两个序的时候，两个无穷小是不同的，一个的无穷小是另一个的无穷大。严格地说，我们选取两个字符 $\#_0, \#_1$ ，使 $\forall x, \forall \ell$ ，应当有 $\#_\ell \prec_\ell x$ ；也就是说， $\#_0 \prec_0 \$ \prec_0 x \prec_0 \#_1, \#_1 \prec_1 x \prec_1 \$ \prec_1 \#_0$ 。（这一串看起来容易眼花...）然后求 $\#_0 w \$$ 关于 \prec_0 的 Lyndon 树 T_0 和 $\#_1 w \$$ 关于 \prec_1 的 Lyndon 树 T_1 。

4.1 应用

设询问 $\text{exrun}([l..r])$ 为包含 $[l..r]$ 、周期不超过 $\frac{r-l+1}{2}$ 的 run，如果存在。他显然至多一个。这个东西是可以 $O(1)$ 求的。

对于 $\text{exrun}([l..r])$ ，设 $m = \lceil \frac{l+r}{2} \rceil$ 。我们在 T_0 和 T_1 上分别寻找 $[l..m]$ 的 LCA，记作 α_0, α_1 ，对他们的右孩子 β_0, β_1 分别求以 β 为 L-root 的 run。答案如果存在，一定是这两个之一。

证明：假设答案存在 $r = (i, j, p)$ ，设 ℓ 满足 $w[j+1] \prec_\ell w[j+1-p]$ ，由于 $p \leq \lfloor (j-i+1)/2 \rfloor$ ，我们有 $l \leq m-p < m+p-1 \leq j$ ，因此 (i, j, p) 一定有一个 Lyndon 根包含 m 位置。设这一 Lyndon 根叫 λ ，它一定在 α_ℓ 的子树内。我们用反证法证明 λ 就是 α_ℓ 的右孩子。设 $\beta \neq \lambda$ 是 α_ℓ 的右孩子，由于三者都包含 m 位置， λ 必然是 β 的子树内某个节点的右孩子。设 $\lambda = [i_\lambda .. j_\lambda], \beta = [i_\beta .. j_\beta]$ 。有 $i \leq l < i_\beta < i_\lambda < r \leq j$ 。讨论 j_β 和 j 的相对大小。如果 $j_\beta \leq j$ ，那么 $\beta \subset [i..j]$ ，那么 β 就会有一个非平凡的周期，和 Lyndon 性矛盾；如果 $j_\beta > j$ ，由 $w[j+1] \prec_\ell w[j+1-p]$ ，可以得到 $w[i_\lambda .. j_\beta] \prec_\ell w[i_\beta .. j_\beta]$ ，和 Lyndon 性矛盾。

5 参考文献

- [0] 金策. 在 WC2017 上的讲课.
- [1] BANNAI H, I T, INENAGA S, 等. The 《Runs》 Theorem[J]. SIAM Journal on Computing, 2017, 46(5): 1501–1514. DOI:10.1137/15M1011032.
- [2] LOUZA F A, MANTACI S, MANZINI G, 等. Inducing the Lyndon Array[J/OL]. arXiv:1905.12987 [cs], 2019[2020-03-11]. <http://arxiv.org/abs/1905.12987>.